INSTITUCION UNIVERSITARIA IBEROAMERICANA

INTELIGENCIA ARTIFICIAL

Actividad 3 - Métodos de aprendizaje supervisado

Descripción de los datos

Trabajo de:

SANTIAGO DUQUE MORA

GERALDINE RÍOS

Docente:

SANDRA ISABEL RODRIGUEZ BAUTISTA

Fecha de elaboración:

9 de octubre de 2026

Continuidad y procedencia

En la Actividad 2 se trabajaron las rutas del Metro de Medellín. Esta actividad continúa el proyecto con el análisis de la demanda en ocho estaciones.

Se revisaron el portal de datos abiertos y los metadatos de afluencia del Metro. Para este ejercicio se creó una muestra simulada, ya que no se contó con un archivo verificado que reuniera estación, hora, día, lluvia y evento. El enunciado permite desarrollar una muestra de datos.

Unidad de observación y tamaño

Cada fila representa un escenario hipotético de demanda de una estación durante una franja de una hora. Son 5,000 escenarios generados con semilla 42; se retiran 27 duplicados exactos y se utilizan 4,973 filas. No existe fecha ni secuencia temporal real. El muestreo de horas y días es uniforme, no proporcional al servicio.

Estaciones: Acevedo, Estadio, Itagüí, La Estrella, Niquía, Poblado, San Antonio, San Javier.

Definición de ocupación

La variable nivel_ocupacion clasifica la demanda: baja hasta 350 pasajeros, media entre 351 y 800 y alta desde 801. Son umbrales definidos para el ejercicio; no representan el porcentaje de ocupación de los trenes.

Diccionario de datos

Campo	Tipo y significado
estacion	Texto. Una de ocho estaciones del modelo anterior.
linea	Texto. Línea A o B de referencia; San Antonio se codifica en A aunque permite transbordo.
hora	Entero, 5 a 21. Franja horaria simulada.
dia_semana	Entero, 0 lunes a 6 domingo.
es_festivo	Binario, probabilidad simulada 0,06. No consulta calendario.
lluvia	Binario, probabilidad simulada 0,25.
evento_especial	Binario, probabilidad simulada 0,05.
pasajeros	Entero ≥20. Conteo simulado por franja; no capacidad.
nivel_ocupacion	Etiqueta baja/media/alta según umbrales académicos.

Generación reproducible

La base por estación va de 280 a 560. Se multiplica por 2,4 en horas pico laborables (6–8 y 17–19), por 1,2 entre las 10 y las 16 en otros casos y por 0,55 en las restantes franjas. Un día no laborable multiplica por 0,70; lluvia por 0,86; evento por 1,45. Se incorpora ruido lognormal con sigma 0,22 y media aritmética 1. Se redondea y aplica mínimo 20. Todos estos factores son supuestos didácticos sin calibración.

generar_dataset.py conserva la fórmula y las bases de cada estación. dataset_transporte.metadata.json registra semilla, versión de NumPy y SHA-256. Ambas actividades usan exactamente el mismo CSV. La regeneración con las versiones fijadas permite verificar su integridad.

Uso en el componente

Se emplean estación, línea, hora, día, festivo, lluvia y evento para predecir la clase. pasajeros se excluye porque la etiqueta deriva de él. El preprocesamiento se aprende dentro de cada partición; la prueba final queda separada.

Límites de interpretación

Los resultados dependen de los supuestos de la simulación. Para aplicarlos al servicio real sería necesario trabajar con mediciones por fecha y estación y comprobar su comportamiento en otros periodos. La comparación entre escenarios con y sin lluvia es descriptiva.

Fuentes consultadas y referencia del curso

Proyecto anterior: estaciones y reglas

Metro de Medellín: transparencia y acceso a datos

Metadatos oficiales: afluencia del sistema Metro

scikit-learn: validación cruzada

scikit-learn: agrupamiento

Consulta de recursos web: 9 de octubre de 2026. Los documentos oficiales se usan como contexto y búsqueda de fuentes; no son el origen de las filas simuladas.

Lectura asignada: Palma Méndez, J. T. (2008). Inteligencia artificial: métodos, técnicas y aplicaciones. McGraw-Hill España. Capítulo 17: Aprendizaje de árboles y reglas de decisión. Lectura pendiente de revisión.